



UTILIZAÇÃO DE REDES NEURAIS ARTIFICIAIS NA PREVISÃO DA GERAÇÃO DE RESÍDUOS SÓLIDOS URBANOS

ERIK JÚNIOR PAULINO – erik.paulino@unesp.br
UNIVERSIDADE ESTADUAL PAULISTA - UNESP – BAURU

FERNANDO BERNARDI DE SOUZA - fbernardi@unesp.br
UNIVERSIDADE ESTADUAL PAULISTA - UNESP – BAURU-FEB

EDMÉA CÁSSIA BAPTISTA - edmea.c.baptista@unesp.br
UNIVERSIDADE ESTADUAL PAULISTA - UNESP – BAURU-FC

ADRIANA CRISTINA CHERRI NICOLA - adriana.cherri@unesp.br
UNIVERSIDADE ESTADUAL PAULISTA - UNESP – BAURU-FC

Área: 1. GESTÃO DA PRODUÇÃO

Sub-Área: 1.1 - GESTÃO DE SISTEMAS DE PRODUÇÃO

Resumo: Com os processos de desenvolvimentos social ocorridos nas últimas décadas, a produção crescente de resíduos sólidos urbanos (RSU) tem tomado importância cada vez maior na gestão dos municípios. O gerenciamento da cadeia de geração do RSU exige técnicas de engenharia eficientes para subsidiar decisões de planejamento e controle. Um ponto importante é capacidade que o gestor deve ter de fazer previsões acertivas no meio produtivo. Na literatura encontram-se diferentes técnicas de previsão, cada qual mais ou menos apropriada para a realidade do setor produtivo. Neste sentido, este trabalho teve por objetivo avaliar o desempenho preditivo de Redes Neurais artificiais na previsão da geração de resíduos sólidos na cidade de Bauru-SP. Pôde-se concluir que rede neural gerada apresentou precisão satisfatória e resultado próximo quando comparada com a técnica tradicional de médias móveis.

Palavras-chaves: PREVISÃO; REDES NEURAIS; RESÍDUO SÓLIDO URBANO

USE OF ARTIFICIAL NEURAL NETWORKS IN THE FORECAST OF THE GENERATION OF URBAN SOLID WASTE

Abstract: *The social development processes occurring in the last decades, the increasing production of urban solid waste (USW) has become increasingly important in the management of municipalities. Managing the USW generation chain requires efficient engineering techniques to support planning and control decisions. An important point is the ability of the manager to make accurate forecasts in the productive environment. In the literature, different forecasting techniques are available, each more or less appropriate to the reality of the productive sector. In this sense, this work had the objective of evaluating the predictive performance of Artificial Neural Networks in the prediction of solid waste generation in the city of Bauru from São Paulo. It was concluded that the generated neural network presented satisfactory accuracy and close result when compared to the traditional moving average technique.*

Keywords: FORECAST; NEURAL NETWORKS; URBAN SOLID WASTE

1. Introdução

A partir da segunda metade do século 20 o Brasil passou por uma rápida mudança de um país predominantemente rural para um país urbano. Segundo dados do Instituto Brasileiro de Geografia e Estatística (IBGE, 2010), 80% da população brasileira vivem em centros urbanos. Esse processo de urbanização atrelado ao maior grau de industrialização dos bens de consumo geraram desafios de gestão dos impactos ambientais nos centros urbanos.

Mudanças de hábitos e costumes das pessoas como o elevado consumo de bens materiais e produtos industrializados criaram problemas como a geração de grande quantidade de resíduos sólidos urbanos (RSU). Esse resíduo deixou de ser predominantemente orgânico para conter materiais sólidos de difícil decomposição.

Dentre os impactos ambientais decorrentes da destinação inadequada do resíduo pode-se observar a contaminação do solo e da água, a obstrução de sistemas de drenagem de água e esgoto, a proliferação de vetores causadores de doenças e a desvalorização imobiliária. Dar um destino adequado para o lixo é uma questão cada vez mais importante nas cidades, sejam elas de pequeno, médio ou de grande porte.

Portanto, "deve-se pensar o lixo como um problema sanitário de primeira ordem, para cuja solução é requerido um processo gerencial bem planejado e estruturado em bases técnicas estabelecidas a partir de soluções de engenharia" (CARVALHO, 2001, *apud* PAES 2004).

A gestão de toda a cadeia do RSU tem sido um desafio para os gestores municipais, onde é preciso identificar a composição do material gerado para que se dê a destinação adequada, seja encaminhando para cooperativas de reciclagem conduzindo para aterros sanitários. Além da composição outra variável fundamental para o planejamento urbano é a quantificação da geração de resíduo, tendo em vista que a complexidade aumenta à medida que a população cresce, pois as fontes produtoras tendem a tornarem-se mais numerosas.

A quantidade de resíduo urbano produzido é bastante variável e depende de uma série de fatores, como tamanho da população, época do ano, renda, modo de vida: cultura, movimento da população nos períodos de férias e fins de semana (PAES 2004). No entanto, a quantificação é de extrema importância na organização e gerenciamento da cadeia de resíduos, desde a sua geração até a destinação adequada. Um gerenciamento municipal inteligente deve ser capaz de lidar não somente com a situação presente, mas também ter a

capacidade de identificar tendências na produção de resíduo e também realizar previsões da quantidade produzida. Tais previsões são necessárias para uma melhor administração pública: adequação da infraestrutura de coleta e transporte, dimensionamento de locais de deposição (aterros), gestão financeira de recursos e otimização de programas de coleta seletiva.

O conhecimento do cenário atual a respeito da quantidade de resíduos existentes e de métodos de projeção da geração dos mesmos ao longo dos anos é um processo de grande importância para se alcançar um gerenciamento focado em um planejamento eficaz e em instalações eficientes (CHUNG, 2010).

Para realizar previsões podem-se utilizar abordagens quantitativas e abordagens qualitativas. As abordagens qualitativas geralmente são baseadas em fatores subjetivos ou de julgamento. Já as abordagens quantitativas baseiam-se na análise de períodos históricos e na projeção de padrões de comportamento para o futuro (CORRÊA, 2007). A decisão sobre qual abordagem utilizar pode-se fundamentar sobre a disponibilidade de um histórico de dados e também sobre qual horizonte se necessita fazer a previsão. Nesse sentido, abordagens quantitativas são mais adequadas para horizontes de previsão curtos já que o padrão identificado no passado pode não se repetir em um futuro relativamente distante.

Existem diferentes modelos quantitativos para previsão de demanda, como a média móvel, a suavização exponencial ou modelos de regressão. Modelos mais simples como a média móvel e a suavização exponencial são baseados no padrão de demanda da série histórica e na inter-relação de seus componentes como tendência, sazonalidade, ciclo e erro aleatório. Modelos de regressão procuram estabelecer uma relação entre a demanda (variável dependente) e variáveis que afetam a demanda (variáveis independentes) e consideram que os parâmetros do modelo matemático utilizado permanecem constantes com o tempo (LEMONS 2006).

O desenvolvimento do poder de processamento dos computadores tem estimulado o uso de novos métodos quantitativos nas empresas e outros setores de produção. Onde técnicas como mineração de dados buscam extrair conhecimento da base de dados acumulada e fazer previsões. Dentre estas técnicas incluem-se árvores de decisão, métodos de indução de regras, lógica fuzzy, redes neurais artificiais, entre outras (GARGANO & RAGGAD, 1999).

O objetivo deste trabalho foi avaliar o desempenho de redes neurais artificiais (RNA) na previsão da geração de resíduo sólido urbano na cidade de Bauru e comparar com a técnica da média móvel de previsão.

2. Material e Métodos

O município de Bauru está localizado no centro-oeste do estado de São Paulo e ocupa uma área de aproximadamente 668 km². Com uma população estimada em 362.348 habitantes é o 18º mais populoso do estado, sendo que 98% dessa população encontram-se em zona urbana (SEADE, 2019). De acordo com a Companhia Ambiental do Estado de São Paulo, em 2018 foram recolhidos em média 331,2 t/dia de resíduo sólido urbano (CETESB, 2018). Segundo estimativa realizada pela prefeitura de Bauru aproximadamente 30% do RSU coletados são recicláveis (SEMMA, 2014).


Para este trabalho foi considerada a geração de resíduo sólido urbano durante um horizonte de 39 anos, de 1980 até 2018. A estimativa foi realizada através dos índices de produção que a CETESB utiliza em função do números de habitantes do município (Tabela 1). Já as populações anuais foram obtidas da Fundação Sistema Estadual de Análise de Dados (SEADE, 2019) através do site da instituição (Figura 1).

TABELA 1 – Índices estimativos de produção per capita de RSU adotados em função da população urbana.

População	Produção (kg/hab.dia)
Até 25.000	0,7
De 25.001 a 100.000	0,8
De 100.001 a 500.000	0,9
Maior que 500.000	1,1

Fonte: CETESB (2018).

FIGURA 1 – População 1980-2019 na cidade de Bauru-SP. Fonte: SEADE (2019).




2.1. Redes Neurais Artificiais

Uma rede neural artificial (RNA) simula o funcionamento do cérebro através de unidades básicas chamadas neurônios artificiais que processam os dados introduzidos na rede. Nas redes do tipo multicamadas os neurônios se organizam em camadas onde cada neurônio se conecta e envia informação para todos os neurônios da camada seguinte (Figura 2). As entradas são apresentadas na primeira camada. Essa camada encaminha a informação para as camadas seguintes. A última camada é chamada camada de saída, onde a solução do problema é obtida.

Basicamente, o treinamento de uma RNA consiste em um problema de minimização não linear sem restrições, em que os pesos sinápticos da rede são iterativamente modificados para minimizar o erro quadrático médio entre a resposta desejada a partir dos dados de entrada e a saída obtida no neurônio de saída (OLIVEIRA., et al. 2010).

FIGURA 2 – Modelo de Redes Neurais multicamadas.



Para implementar a RNA utilizou-se dois neurônios na camada de entrada, oito neurônios na camada intermediária e um neurônio na camada de saída. O algoritmo utilizado para treinamento foi o algoritmo *Resilient Propagation* com taxa de aprendizagem de 0,01. Definiu-se o conjunto de treinamento como a produção de RSU de 1980 até 2013. Os dados do período de 2014 a 2018 foram reservados para avaliar a eficiência preditiva da RNA.

Também foi utilizado o método de previsão da média móvel, onde o valor previsto neste caso foi considerado empiricamente como a média aritmética das quatro produções anteriores de RSU tendo em vista que o padrão de geração teve pouca variação. Para comparar a qualidade das previsões da RNA com o método de média móvel foi utilizado o erro percentual médio absoluto (MAPE) e o erro quadrático médio de previsão (EQMP):

$$MAPE = \frac{1}{h} \sum_{i=1}^h \left| \frac{y_i - y_{pi}}{y_i} \right|; EQMP = \frac{1}{h} \sum_{i=1}^h (y_i - y_{pi})^2$$

em que:


y_i é o valor real do período i

y_{pi} é a previsão para o período i
 h é o número de previsões

3. Resultados e Discussão

Ao observarmos a produção anual de RSU (tonelada/dia) no horizonte de avaliação, verificamos que produção praticamente dobra do período inicial até o final. Outro fato importante é que ocorre uma desaceleração a partir do ano 2000 (Figura 3). Este comportamento é influenciado pela taxa de crescimento da população tendo em vista que a produção de RSU foi calculada diretamente a partir da população anual.

FIGURA 3 – Produção de RSU anual (ton/dia).



Na Tabela 2 são apresentadas as previsões para os anos de 2014 a 2018 obtidos pela RNA e através da média móvel. Pode-se observar que tanto as previsões da RNA quanto da média móvel ficaram muito próximas. Este resultado é explicado pelo padrão de aumento na geração de RSU ter pouca variação, exceto próximo do ano 2000.

TABELA 2 – Valores reais e previstos pela RNA e média móvel.

Ano	Valor Real	RNA	Média Móvel
2014	317,4	312,6	312,3
2015	319,4	313,1	313,1
2016	321,1	313,4	313,5
2017	322,8	313,7	313,6
2018	324,4	313,9	313,1

Na tabela 3 são apresentados o MAPE e o EQMP para as previsões da rede neural e da média móvel. O desempenho da RNA foi ligeiramente superior a média móvel nos dois indicadores. Observa-se que a RNA tendeu-se a ser mais precisa à medida que aumentou o

horizonte de previsão de RSU. Esta tendência é justificada pelo fato da média móvel ser mais indicada para previsões de curto prazo.

TABELA 3 – Comparação da precisão das previsões obtidas pela RNA e Média Móvel durante o período de 2014 a 2018.

Modelo	MAPE	EQMP
RNA	2,4%	62,6
Média Móvel	2,5%	67,0

4. Considerações Finais

O modelo de RNA apresentou um bom desempenho na previsão da geração de RSU em todos os períodos avaliados. Os resultados obtidos pela RNA ficaram próximos daqueles obtidos pela média móvel, sendo observada uma ligeira superioridade na previsão da RNA.

Os dados de geração de RSU utilizados apresentaram pouca variação de tendência no horizonte de tempo avaliado. Isso pode ter influenciado a pouca diferença na previsão entre os dois métodos.

Para trabalhos futuros podem ser testadas novas configurações de redes neurais, como diferentes algoritmos e arquiteturas.

Referências

- CARVALHO, L.E.X. (2001) Desenvolvimento de solução integrada de sistemas de limpeza urbana em ambiente SIG. Dissertação (Mestrado em Ciências em Engenharia de Transportes), Rio de Janeiro–RJ, Universidade Federal do Rio de Janeiro – UFRJ, 240 p.
- COMPANHIA AMBIENTAL DO ESTADO DE SÃO PAULO – CETESB. Inventário Estadual de Resíduos Sólidos Urbanos, 2018.
- CORRÊA, H.L.; CORRÊA, C.A. Administração da Produção e Operações: manufatura e serviços – uma abordagem estratégica. São Paulo: Atlas, 2007.
- CHUNG, S S. Projecting municipal solid waste: The case of Hong Kong SAR. Resources, Conservation and Recycling, v.54, p. 759-768, 2010.
- FUNDAÇÃO SISTEMA ESTADUAL DE ANÁLISE DE DADOS – SEADE (2019) <<http://www.seade.gov.br/>> Acesso em 25 jun 2019.
- GARGANO, Michael L.; RAGGAD, Bel G., 1999. Data mining - a powerful information creating tool. OCLC Systems and Services, MCB University Press, v. 15, n. 2, págs. 81-90.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA - IBGE. Censo 2010. População residente por situação de domicílio, 2010.

LEMONS, F.O. Metodologia para Seleção de Métodos de Previsão de Demanda. Dissertação (Mestre em Ciências da Engenharia de Produção), Universidade Federal do Rio Grande do Sul, 2006. 183 p.

OLIVEIRA ACS, SOUZA AA, LACERDA WS, GONÇALVES LR. Aplicação de redes neurais artificiais na previsão da produção de álcool. Ciênc Agrotec. 2010; 34(2): 279-84.

PAES, F.G. Otimização de Rotas para a Coleta do Lixo Doméstico: Um Tratamento GRASP do Problema do Carteiro Chinês Misto (PCCM). Dissertação (Mestre em Ciências da Engenharia), Campos dos Goytacazes-RJ, Universidade Estadual do Norte Fluminense, 2004. 129 p.

situação de domicílio, 2010.

SECRETARIA MUNICIPAL DE MEIO AMBIENTE DE BARU – SEMMA. Plano Municipal de Saneamento Básico - Variável Limpeza Urbana e Manejo de Resíduos sólidos, 2014. Disponível em: <http://www.bauru.sp.gov.br/semma/plano_residuos.aspx>. Acesso em: 25 jun. 2019.